

Guía de práctica de laboratorio

Esteganografía y estegoanálisis

Experimentación práctica y análisis estructural con la herramienta Aletheia

Objetivos de la práctica

- Comprender los principios de ocultación de información en portadores digitales (imágenes).
- Diferenciar entre técnicas esteganográficas espaciales (LSB *Replacement* frente a LSB *Matching*) y de dominio frecuencial (modificación de coeficientes DCT en JPEG).
- Utilizar ataques estadísticos estructurales de primer y segundo orden (Ataque SPA) para detectar anomalías.
- Evaluar la eficacia del estegoanálisis basado en clasificadores avanzados de *Machine Learning* (Redes Neuronales Convolucionales).
- Interpretar las funciones de coste adaptativas mediante la visualización espacial de las modificaciones sufridas por el portador.

Introducción teórica breve

La esteganografía es la disciplina encargada de ocultar la existencia misma de un mensaje dentro de un portador inocuo (denominado *cover*), dando lugar a un portador modificado (*stego*). El estegoanálisis es la contrapartida que busca detectar la presencia de dicha información oculta.

En el dominio espacial, la técnica más básica consiste en la sustitución del bit menos significativo (LSB *Replacement*), donde los bits del mensaje reemplazan directamente el LSB de los píxeles. Esto genera una asimetría estadística medible debido a que los valores pares e impares modifican sus transiciones de paridad de forma predecible. Técnicas más avanzadas, como LSB *Matching* o los algoritmos adaptativos (por ejemplo, UNIWARD), introducen variaciones sumando o restando una unidad aleatoriamente y concentrando las modificaciones en zonas con alta textura, bordes o ruido para burlar el análisis estadístico y visual.

Estructura de la práctica y pasos de la ejecución

Paso 1: Configuración del entorno y despliegue de herramientas

El propósito de este primer bloque es preparar una estación de trabajo autocontenida que simule las dependencias de producción de un analista forense digital. Se requiere la *suite* Aletheia, un entorno avanzado de estegoanálisis de código abierto.

¿Por qué instalamos estos componentes?

- **Tensorflow, steganogan y efficientnet:** soportan la ejecución de modelos de aprendizaje profundo entrenados para capturar patrones complejos de ruido esteganográfico.

- **Steghide y outguess:** actúan como herramientas de inserción clásicas para generar muestras de control en formatos JPEG.
- **Octave y sus extensiones (octave-image, octave-signal):** son esenciales, dado que gran parte de los algoritmos del estado del arte del estegoanálisis adaptativo dependen de estas librerías matemáticas para calcular matrices de coocurrencia y filtros de extracción.

```
!pip install tensorflow steganogan efficientnet hdf5storage
!apt-get install -y steghide outguess imagemagick octave octave-image octave-signal
!git clone https://github.com/bwall/Aletheia.git
```

Paso 2: Detección inicial mediante ataques estadísticos estructurales

Antes de procesar imágenes complejas, se debe estudiar el impacto de los ataques directos sobre algoritmos simétricos. En este paso se aplica el análisis de pares de muestras (*Sample Pair Analysis*, SPA) sobre una imagen clásica modificada por sustitución pura (lena_lsbr_0.3.png).

El ataque SPA se fundamenta en modelar las transiciones de los conjuntos de píxeles colindantes que tienen valores de paridad específicos. Al realizar una sustitución directa, el histograma sufre una distorsión geométrica muy marcada. El *script* detectará *payloads* ocultos de forma independiente en los canales independientes de color: rojo (R), verde (G) y azul (B).

```
!python Aletheia/aletheia.py spa aletheia-models/images/lena_lsbr_0.3.png
```

Pregunta para el informe

Observa el porcentaje de *payload* estimado por el ataque SPA en cada canal. Si la imagen original tuviera una tasa de ocultación del 30%, ¿es preciso el ataque estadístico? ¿Por qué crees que este ataque estructural pierde efectividad si se aplicara sobre imágenes generadas con *LSB Matching* en lugar de *LSB Replacement*?

Paso 3: Estegoanálisis basado en aprendizaje profundo (*Deep Learning*)

Cuando los atacantes emplean herramientas que preservan los histogramas de primer orden, los ataques estructurales clásicos como SPA fallan. Es aquí donde intervienen las Redes Neuronales Convolucionales (*Convolutional Neural Networks*, CNN). En esta sección se invoca el submodelo *effnetb0-predict*, entrenado específicamente sobre redes *EfficientNetB0* para identificar la firma difusa que deja el software *Steghide* al incrustar mensajes en ficheros JPEG.

```
!python Aletheia/aletheia.py effnetb0-predict MUESTRAS/steghide/ 0.5
```

El parámetro 0.5 representa el umbral de decisión para clasificar una imagen como *stego*. El *script* evaluará un lote completo de imágenes y devolverá la probabilidad individual de alteración de cada archivo.

Nota de ingeniería forense

Los modelos basados en *Machine Learning* dentro de Aletheia no buscan un texto legible; detectan la alteración de las correlaciones naturales entre coeficientes vecinos producidas al forzar la inserción de datos.

Paso 4: Simulación de ataques y caracterización de herramientas desconocidas

Para comprender cómo operan los diferentes programas disponibles en la red, el estudiante descargará un banco de imágenes limpias y ejecutará inserciones controladas a una ratio fija de capacidad simulada (*payload* aproximado del 5%, equivalente a un factor de tasa de bits de 0,05). Se comparan tres paradigmas:

1. **OpenStego**: actúa en el dominio espacial sobre formatos sin pérdida (PNG).
2. **Steghide**: actúa en el dominio frecuencial (JPEG) mediante la sustitución selectiva de coeficientes DCT (Discrete Cosine Transform).
3. **HStego (UNIWARD / J-UNIWARD)**: esteganografía adaptativa de última generación que calcula una función de distorsión antes de modificar el portador.

Posteriormente, se utiliza el subcomando `print-diffs` o `print-dct-diffs` para realizar una inspección a bajo nivel de las modificaciones elementales.

```
!python Aletheia/aletheia.py print-diffs cover.png stego_openstego.png
```

Pregunta para el informe

Al ejecutar `print-diffs` sobre una imagen generada con OpenStego verás que las diferencias de los valores de los píxeles son estrictamente constantes (+1 o -1). En cambio, al analizar herramientas adaptativas, muchas diferencias se omiten en áreas “planas”. Explica detalladamente cómo ayuda la función de coste de un algoritmo adaptativo (como UNIWARD) a evadir los filtros de detección automatizados.

Paso 5: Visualización espacial de la incrustación adaptativa

El último bloque del laboratorio consiste en la ejecución del script analítico programado en Python puro integrado en el notebook. Este método toma la matriz de la imagen original (*cover*) y la de la imagen modificada (*stego*), calcula el valor absoluto de la resta de sus componentes y mapea las variaciones exactas sobre una máscara gráfica donde los píxeles modificados se tiñen de color rojo brillante.

```
def plot_diff(cover_path, stego_path):
    # Carga de imágenes y cálculo de diferencias absolutas
    # Los píxeles alterados se marcan en un lienzo de contraste
    ...
plot_diff('cover.jpg', 'stego_hstego.jpg')
```

Al ejecutar esta función sobre imágenes procesadas con esteganografía convencional frente a esteganografía adaptativa, los estudiantes observarán dos patrones radicalmente opuestos: una

distribución uniforme y pseudoaleatoria (OpenStego/Steghide tradicional) versus una distribución concentrada exclusivamente en los bordes texturizados del objeto (HStego/UNIWARD).

Pregunta para el informe (conclusión del laboratorio)

Adjunta la captura gráfica generada por la función `plot_diff` en tu memoria. Describe las diferencias observadas en la localización de los píxeles modificados entre el método espacial clásico y el método adaptativo frecuencial. ¿Por qué el ojo humano es incapaz de percibir las alteraciones incluso en las zonas marcadas en rojo?

Instrucciones para la entrega de la memoria – (no para Cyber Bootcamp, Málaga)

Cada estudiante o equipo de laboratorio deberá entregar un informe en formato PDF que incluya de forma obligatoria:

- Las respuestas razonadas a las tres preguntas planteadas a lo largo de este guion.
- Las capturas de pantalla de la terminal que demuestren la ejecución correcta de los comandos de Aletheia (SPA y predicción EffNet).
- Un breve análisis crítico indicando cuál de las herramientas estudiadas consideran más segura frente a una auditoría forense y por qué.